

머신러닝

데이터의 이해

Chapter 2



Prof. Yang



한국성서대학교
KOREAN BIBLE UNIVERSITY

목 차

CONTENTS

01 피쳐란?

02 피쳐의 종류


03 데이터를 모델에 대입하기

01 피쳐란?



머신러닝 예시

- 영화관 관람객 수 y 를 인터넷 웹사이트의 좋아요 개수 x 로 예측할 수 있다고 가정하면 영화관의 관람객 수와 좋아요 개수의 관계를 $f(x)$ 로 표현할 수 있음





피쳐의 개념

- 피쳐(Feature) : '특성'이나 '특징'이라는 의미
- 모델을 구성하는 데 데이터가 가장 큰 영향을 줌
- 모델은 함수 형태로 표현

$$y = f(x)$$




그림 2-1 $y = ax + b$ 모델



피쳐의 예시

- 보스턴 집값 예측(Boston House Price) 데이터셋

x 변수 13개	[01] CRIM	자치시(town)별 1인당 범죄율
	[02] ZN	25,000 평방피트를 초과하는 거주지역의 비율
	[03] INDUS	비소매상업지역이 점유하고 있는 토지의 비율
	[04] CHAS	찰스강에 대한 더미변수(강의 경계에 위치한 경우는 1, 아니면 0)
	[05] NOX	10ppm 당 농축 일산화질소
	[06] RM	주택 1가구당 평균 방의 개수
	[07] AGE	1940년 이전에 건축된 소유주택의 비율
	[08] DIS	5개의 보스턴 직업센터까지의 접근성 지수
	[09] RAD	방사형 도로까지의 접근성 지수
	[10] TAX	10,000달러 당 재산세율
	[11] PTRATIO	자치시(town)별 학생/교사 비율
	[12] B	$1000(B_k - 0.63)^2$, 여기서 B_k 는 자치시별 흑인의 비율을 말함
	[13] LSTAT	모집단의 하위계층의 비율(%)
y 변수	[14] MEDV	본인 소유의 주택가격(중앙값) (단위 : \$1,000)

그림 2-3 보스턴 집값 예측(Boston House Price) 데이터셋



피쳐의 예시

- 범죄율, 방의 개수, 재산세율 등의 값들이 어떻게 집값(종속변수 = y)에 영향을 주는지에 대한 모델
- 서로 다른 독립변수 13개를 x_n 으로 하고 가중치 β_n 을 선형 결합(Linear Combination)하여 나타냄

$$y = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \cdots + \beta_{13} x_{13} + \beta_0 \times 1$$

$$y = w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 x_4 + \cdots + w_{13} x_{13} + w_0 \times 1$$

위 표현식 중 β_n 은 통계학에서 흔히 사용하는 표현
일반적으로 머신러닝에서는 가중치를 의미하는 w 를 많이 사용함

- 머신러닝에서는 독립변수 x 를 피쳐라고 부름
 - 종속변수 y 에 영향을 주는 특성, 데이터가 가지고 있는 특성



피쳐의 표기법

- 데이터 테이블(Data Table) : 데이터를 테이블(표)로 표현한 것
 - 모판 : '데이터의 판'이라는 의미로 사용
- 피쳐(Feature): 데이터 테이블 상에서 하나의 열(Column)에 해당
 - "Column=열=Feature=특성=Attribute=속성" 모두 같은 의미
- 데이터 인스턴스(Data Instance) : 하나의 데이터
 - "Row=행=Tuple=Instance" 모두 같은 의미

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
0	0.00632	18.0	2.31	0.0	0.538	6.575	65.2	4.0900	1.0	296.0	15.3	396.90	4.98	24.0
1	0.02731	0.0	7.07	0.0	0.469	6.421	78.9	4.9671	2.0	242.0	17.8	396.90	9.14	21.6
2	0.02729	0.0	7.07	0.0	0.469	7.185	61.1	4.9671	2.0	242.0	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0.0	0.458	6.998	45.8	6.0622	3.0	222.0	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0.0	0.458	7.147	54.2	6.0622	3.0	222.0	18.7	396.90	5.33	36.2
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
501	0.06263	0.0	11.93	0.0	0.573	6.593	69.1	2.4786	1.0	273.0	21.0	391.99	9.67	22.4
502	0.04527	0.0	11.93	0.0	0.573	6.120	76.7	2.2875	1.0	273.0	21.0	396.90	9.08	20.6
503	0.06076	0.0	11.93	0.0	0.573	6.976	91.0	2.1675	1.0	273.0	21.0	396.90	5.64	23.9
504	0.10959	0.0	11.93	0.0	0.573	6.794	89.3	2.3889	1.0	273.0	21.0	393.45	6.48	22.0
505	0.04741	0.0	11.93	0.0	0.573	6.030	80.8	2.5050	1.0	273.0	21.0	396.90	7.88	11.8

모든 데이터를 아래와 같은 수식적으로 표현해야함


$$y = w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + \cdots + w_{13}x_{13} + w_0 \times 1$$

=> 데이터를 행렬로 표현하여 수식화 함



행렬(matrix) 정의

★ 데이터 용어 Scalar Vector Matrix ~~Tensor~~



- 행렬(matrix)? 수나 식을 사각형 모양으로 배열하고 괄호로 묶어 놓은 것

$$\begin{bmatrix} 2 & 4 & 1 \\ 5 & 7 & 2 \end{bmatrix} \quad \begin{bmatrix} a & a^2 & a^3 \\ a+b & a & 2b^2 \\ b^2 & ab & 3b \end{bmatrix}$$

- 성분(원소, element)
- 행(row)
- 열(column)

$$A_{m \times n} = \begin{matrix} & \begin{matrix} 1\text{열} & 2\text{열} & \cdots & n\text{열} \end{matrix} \\ \begin{matrix} 1\text{행} \\ 2\text{행} \\ \vdots \\ m\text{행} \end{matrix} & \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix} \end{matrix} = (a_{ij})$$



벡터

- 행이나 열이 하나 밖에 없는 행렬
 - 행벡터(row vector)

$$A = [4 \quad 5 \quad 6 \quad 7 \quad 9]$$



```
import numpy as np
A = np.array([4,5,6,7,9])
print(A)
```

[4 5 6 7 9]

- 열벡터(column vector)

$$B = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}$$



```
B = np.array([1,3,5]).reshape(3,1)
print(B)
```

[[1]
[3]
[5]]



행렬의 연산

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}, \quad B = \begin{bmatrix} 6 & 5 \\ 4 & 3 \\ 2 & 1 \end{bmatrix}$$

- 합(덧셈)

$$A + B = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix} + \begin{bmatrix} 6 & 5 \\ 4 & 3 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 1+6 & 2+5 \\ 3+4 & 4+3 \\ 5+2 & 6+1 \end{bmatrix} = \begin{bmatrix} 7 & 7 \\ 7 & 7 \\ 7 & 7 \end{bmatrix}$$

- 차(뺄셈)

$$A - B = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix} - \begin{bmatrix} 6 & 5 \\ 4 & 3 \\ 2 & 1 \end{bmatrix} = \begin{bmatrix} 1-6 & 2-5 \\ 3-4 & 4-3 \\ 5-2 & 6-1 \end{bmatrix} = \begin{bmatrix} -5 & -3 \\ -1 & 1 \\ 3 & 5 \end{bmatrix}$$

- 스칼라배(스칼라곱)


$$10A = 10 \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix} = \begin{bmatrix} 1 \times 10 & 2 \times 10 \\ 3 \times 10 & 4 \times 10 \\ 5 \times 10 & 6 \times 10 \end{bmatrix} = \begin{bmatrix} 10 & 20 \\ 30 & 40 \\ 50 & 60 \end{bmatrix}$$



행렬의 연산

■ 곱 연산

- 행렬끼리의 곱셈에서는 적합성조건(Conformability Condition)이 충족되어야함



■ 방법

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{pmatrix}, B = \begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \\ b_{31} & b_{32} \end{pmatrix} \text{ 일 때 } A \times B$$

$$A \times B = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{pmatrix} \times \begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \\ b_{31} & b_{32} \end{pmatrix} = \begin{pmatrix} a_{11}b_{11} + a_{12}b_{21} + a_{13}b_{31} & a_{11}b_{12} + a_{12}b_{22} + a_{13}b_{32} \\ a_{21}b_{11} + a_{22}b_{21} + a_{23}b_{31} & a_{21}b_{12} + a_{22}b_{22} + a_{23}b_{32} \end{pmatrix}$$



벡터 내적곱 예시

$$w_1x_1 + w_2x_2 + w_3x_3 + \dots + w_nx_n$$

$$\begin{bmatrix} w_1 & w_2 & w_3 \end{bmatrix} \times \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} w_1 \times x_1 + w_2 \times x_2 + w_3 \times x_3 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 2 & 3 \end{bmatrix} \times \begin{bmatrix} 2 \\ 2 \\ 2 \end{bmatrix} = 1 \times 2 + 2 \times 2 + 3 \times 2$$
$$= 2 + 4 + 6$$
$$= 12$$



선형방정식

- 선형방정식(Linear equation)
 - 최고 차항의 차수가 1인 방정식 (일차방정식 $y = ax + b$)

- 연립선형방정식(System of Linear Equations)

- 여러 선형방정식이 모여 있는 것

$$\begin{cases} 2x_1 + 3x_2 + 3x_3 = 9 \\ 3x_1 + 4x_2 + 2x_3 = 0 \\ -2x_1 + 2x_2 + 3x_3 = 2 \end{cases} \quad \rightarrow \quad \begin{cases} 2w_1 + 3w_2 + 3w_3 = 9 \\ 3w_1 + 4w_2 + 2w_3 = 0 \\ -2w_1 + 2w_2 + 3w_3 = 2 \end{cases}$$

- 연립선형방정식의 해: 연립선형방정식의 모든 선형방정식을 만족하는 미지수들의 값
- 행렬과 벡터를 이용하여 표현 가능

$$\begin{bmatrix} 2 & 3 & 3 \\ 3 & 4 & 2 \\ -2 & 2 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 9 \\ 0 \\ 2 \end{bmatrix} \quad \rightarrow \quad \begin{bmatrix} 2 & 3 & 3 \\ 3 & 4 & 2 \\ -2 & 2 & 3 \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix} = \begin{bmatrix} 9 \\ 0 \\ 2 \end{bmatrix}$$



피쳐의 표기법

$$x^{(1)} = \begin{bmatrix} 1 \\ 0.00632 \\ 18 \\ 2.31 \\ 0.538 \\ \vdots \\ 4.98 \end{bmatrix}$$

그림 2-6 벡터 형태로 표현

$$w = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ w_3 \\ \vdots \\ w_{13} \end{bmatrix}$$

- 행(row), 즉 튜플의 값은 열 벡터(column vector)로 표현
- 가중치(weight)도 열 벡터로 표현
- x_j^i
 - x : 튜플
 - i : 전체 데이터 테이블에서 튜플의 순서
 - j : 피쳐의 순서

- 수식을 선형대수 표기법으로 표현

$$y = w_1x_1 + w_2x_2 + \dots + w_{13}x_{13} + w_0x_0 = \sum_{j=0}^{13} w_jx_j = W^T X$$

행렬 곱

- $W^T X$ 는 벡터의 내적으로 열 벡터끼리 같은 위치에 있는 값들을 곱해서 최종적으로 모두 더하는 연산



차원의 저주

- 차원의 저주(Curse of Dimensionality) : 피쳐의 개수가 증가하게 되면 데이터를 표현해야 하는 공간이 지속적으로 늘어나게 되고 이에 대한 처리가 어렵게 되는 것
 - 희박한 벡터 생성 : 벡터 공간에 너무 많은 0이 포함된 형태로 값이 없는 벡터들이 증가하여 모델 전체의 정확도를 떨어뜨림
 - 데이터 처리 속도와 메모리 공간 문제 : 샘플 데이터가 너무 많아져 문제 발생
- 해결방법 “차원 축소”
 - 고차원 공간에서 표현되는 데이터를 저차원 공간의 데이터로 변환하는 것
 - ex) 주성분 분석


2차원





3차원




4차원



5차원



주성분 분석



주성분 축 1

주성분 축 2

02 피쳐의 종류



피쳐의 종류

CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV	CAT.MEDV
0.00632	18	2.31	0	0.538	6.575	65.2	4.09	1	296	15.3	396.9	4.98	24	0

$$y = w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + \dots + w_{13}x_{13} + w_0 \times 1$$

그림 2-8 데이터 인스턴스 추출과 수식 적용

- 데이터는 저마다 피쳐를 가지고 그 피쳐에 맞춰 모델에 넣기 위한 데이터를 변환해줄 필요가 있음
- 데이터의 분류
 - 1) 범주형 : 몇 개의 범주로 나누어진 자료를 의미
 - 명목형 : 성별, 성공여부, 혈액형 등 단순히 분류된 자료
 - 서수형 : 개개의 값들이 이산적이며 그들 사이에 순서 관계가 존재하는 자료
 - 2) 수치형 : 이산형과 연속형으로 이루어진 자료를 의미
 - 이산형 : 이산적인 값을 갖는 데이터로 출산횟수 등을 의미
 - 연속형 : 연속적인 값을 갖는 데이터로 신장, 체중 등을 의미



1) 범주형 데이터

- 명목형 데이터(nominal data) : 카테고리로 분류 가능한 데이터 타입
 - 이산형 데이터의 일종이며 '명목척도'라고도 표현
 - 두 개의 카테고리로만 데이터가 분류된다면 이진형 데이터 타입
 - 예) 학과, 혈액형 등
- 서수형 타입(ordinal data) : 범주형 데이터의 일종이지만 데이터 간의 순서가 존재하는 데이터 타입
 - 예) 옷 사이즈 S, M, L



2) 수치형 데이터

- 이산형 데이터(Discrete Data)
 - 연속적 값이 아니라 분리해서 표현하는 데이터
 - 개별적인 값으로 일반적으로 정수형태로 표현
- 연속형 데이터(Continuous Data)
 - 값이 끊어지지 않고 계속 연결되는 종류의 데이터
 - 일반적으로 실수로 표현
- 연속형 데이터 vs 이산형 데이터

내용	연속형 데이터	이산형 데이터
개념	• 값이 끊어지지 않고 연결되어 표시되는 형태 • 일반적인 실수나 정수 값들	• 값이 연속적이지 않고 끊어서 표현되는 값 • 라벨로 구분되는 값 • 숫자일 경우에도 그 값들 간에 스케일이 존재하지 않음
예시	온도, 시험 평균, 자동차 속도 등	성별, 주소, 설문조사 척도 등



데이터를 모델에 적용할 때 고려사항

CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV	CAT.MEDV
0.00632	18	2.31	0	0.538	6.575	65.2	4.09	1	296	15.3	396.9	4.98	24	0

$$y = w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + \dots + w_{13}x_{13} + w_0 \times 1$$

그림 2-9 데이터 인스턴스 추출과 수식 적용

- 숫자형 데이터인 AGE와 서수형 데이터인 RAD를 같은 형태로 저장해도 되는가?
 - RAD는 '방사형 도로까지의 접근성 지수'이고 기준에 따라 접근성을 숫자로 표현한 것
- AGE와 B는 둘 다 스케일 있는 값이지만 그 범위가 달라서 w_i 값을 구하기 위해 μ 값 범위도 상당히 다르게 해야 함
- 특정 열의 데이터가 아예 존재하지 않거나 일부 존재하지 않을 수도 있고 오기되어 잘못된 데이터들이 있을 수 있음
- 데이터의 성질을 고려하여 머신러닝 모델을 만들어야 함

03

데이터를 모델에 대입하기



데이터 테이블의 기본 용어

데이터 테이블, 샘플

속성, 필드, 피쳐, 열

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
0	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.0900	1	296.0	15.3	396.9	4.98	24.0
1	0.02731	0.0	7.07	0	0.469	6.421	48.9	4.9671	2	242.0	17.8	396.9	9.14	21.6
2	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242.0	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222.0	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222.0	18.7	396.9	5.33	36.2
5	0.02985	0.0	2.18	0	0.458	6.43	58.7	6.0622	3	222.0	18.7	394.12	5.21	28.7
6	0.08829	12.5	2.18	0	0.524	6.012	66.6	5.5605	5	311.0	15.2	395.6	12.43	22.9
7	0.14455	12.5	7.87	0	0.524	6.172	96.1	5.9505	5	311.0	15.2	396.9	19.15	27.1
8	0.21124	12.5	7.87	0	0.524	5.631	100	6.0821	5	311.0	15.2	386.63	29.93	16.5
9	0.17004	12.5	7.87	0	0.524	6.004	85.9	6.5921	5	311.0	15.2	386.71	17.1	18.9
10	0.22489	12.5	7.87	0	0.524	6.377	94.3	6.3467	5	311.0	15.2	392.52	20.45	15.0

인스턴스, 튜플, 행

피쳐 벡터


데이터

그림 2-10 데이터 테이블의 기본 용어



데이터 테이블의 형식

- 데이터를 호출하기 위해서는 데이터 테이블 형태로 저장될 수 있는 타입을 사용
- 다양한 데이터 타입으로 데이터 테이블을 저장
 - 대표적으로 'csv(comma separate value)' 또는 'xlsx' 파일
 - csv: 콤마(,)로 열을 구분하고 줄바꿈(\n)으로 행을 구분하는 파일
 - 트리 형태로 저장되어 있는 'json'이나 'xml'
 - 파이썬에 특화된 데이터 저장 형태인 'pickle'
 - 큰 데이터를 저장하는 이진 데이터 형식인 'h5'





데이터 준비

```
import pandas as pd# (1) pandas 모듈 호출
```

```
#(2)데이터 URL을 변수 data_url에 넣기
```

```
data_url = 'https://archive.ics.uci.edu/ml/machine-learning-databases/housing/housing.data'
```

```
#(3) csv 데이터 로드
```

```
df_data = pd.read_csv(data_url, sep='\s+', header = None) #정규 표현식: '\s+' 공백 하나 이상
```

```
#(4) 데이터의 열 이름 지정
```

```
df_data.columns = ['CRIM', 'ZN', 'INDUS', 'CHAS', 'NOX', 'RM', 'AGE', 'DIS', 'RAD', 'TAX', 'PTRATIO', 'B', 'LSTAT', 'MEDV']  
df_data.head()
```

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
0	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.0900	1	296.0	15.3	396.90	4.98	24.0
1	0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242.0	17.8	396.90	9.14	21.6
2	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242.0	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222.0	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222.0	18.7	396.90	5.33	36.2



데이터에 수식 적용하기

- 적용해야 하는 수식

$$y = w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + \dots + w_{13}x_{13} + w_0 \times 1$$

- 데이터가 벡터가 아닌 매트릭스 형태라서 수식을 변형

$$y = w_1x_1 + w_2x_2 + \dots + w_{13}x_{13} + w_0x_0 = \sum_{j=0}^{13} w_jx_j = W^T X$$

- 두 벡터의 곱셈 연산을 벡터의 내적으로 나타낼 수 있음
- 전체 데이터를 X 로 가중치를 W 로 나타냄



w_0 상수열 추가

```
df_data['weight_0'] = 1 # weight 0 값 추가  
df_data.head()
```

$$y = w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + \dots + w_{13}x_{13} + w_0 \times 1$$

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV	weight_0
0	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.0900	1	296.0	15.3	396.90	4.98	24.0	1
1	0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242.0	17.8	396.90	9.14	21.6	1
2	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242.0	17.8	392.83	4.03	34.7	1
3	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222.0	18.7	394.63	2.94	33.4	1
4	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222.0	18.7	396.90	5.33	36.2	1



X와 y값 분리

- 특히 x데이터는 행렬곱, 즉 벡터 내적 계산해야하므로 넘파이 배열로 변환해야함

```
y = df_data.pop("MEDV")# Y 추출  
x = df_data.values #x 값 행렬(Matrix) 데이터로 변환하기  
print(x)
```

```
[[6.3200e-03 1.8000e+01 2.3100e+00 ... 3.9690e+02 4.9800e+00 1.0000e+00]  
 [2.7310e-02 0.0000e+00 7.0700e+00 ... 3.9690e+02 9.1400e+00 1.0000e+00]  
 [2.7290e-02 0.0000e+00 7.0700e+00 ... 3.9283e+02 4.0300e+00 1.0000e+00]  
 ...  
 [6.0760e-02 0.0000e+00 1.1930e+01 ... 3.9690e+02 5.6400e+00 1.0000e+00]  
 [1.0959e-01 0.0000e+00 1.1930e+01 ... 3.9345e+02 6.4800e+00 1.0000e+00]  
 [4.7410e-02 0.0000e+00 1.1930e+01 ... 3.9690e+02 7.8800e+00 1.0000e+00]]
```




수식 연산하기

- 가중치는 기울기를 결정하는 중요한 요소
- 하지만 처음에는 정확하게 정할 수 없으므로 랜덤하게 생성

```
import numpy as np#numpy 모듈 호출
weight_vector = np.random.choice(10, 14, replace=True)#가중치 w 생성
y_hat=x.dot(weight_vector) #내적 연산 실행 결과=>예상값
y_hat
```

```
array([4707.73624, 4393.20327, 4262.39913, 4061.76279, 4127.79555,
       4129.99315, 4839.34253, 5022.94635, 5022.38078, 4902.75438,
       4994.64493, 4932.86099, 4683.29936, 4722.75382, 4743.37362,
       4688.72833, 4495.93811, 4787.7893 , 3961.34147, 4736.5071 ,
       4835.24243, 4856.73858, 4918.35419, 4947.42821, 4901.42942,
       4314.19638, 4771.05937, 4353.13379, 4853.08763, 4770.15415,
       4723.32267, 4816.88804, 3920.34793, 4702.07524, 4061.55554,
       4578.59249, 4435.35498, 4441.80618, 4370.96765, 4582.58651,
       4544.92423, 3881.38498, 3889.2194 , 3962.07242, 4106.76773,
       4121.64034, 4135.43492, 4391.92629, 4511.75509, 4287.60609,
       4371.85881, 4433.02929, 4226.1649 , 4238.18637, 6074.5569 ,
       4530.31137, 5076.39345, 4831.66804, 4536.69295, 4671.33996,
```



np.random.choice함수	
파라미터	의미
a	0~a-1 범위 - 스칼라값 또는 벡터
size	뽑을 개수
replace	중복 허용 여부
p	각 값이 선택될 확률
반환값	정수형의 스칼라값 또는 벡터



실제값과 예측값의 차이

- 따라서 예측값이 실제 값에 가까워 지도록 가중치를 조절해야함 => 머신러닝 알고리즘

```
print(y) #실제값
```

```
0      24.0
1      21.6
2      34.7
3      33.4
4      36.2
...
501    22.4
502    20.6
503    23.9
504    22.0
505    11.9
```

p.29 "y_hat" 변수에 저장된 예측값

```
array([4707.73624, 4393.20327, 4262.39913, 4061.76279, 4127.79555,
       4129.99315, 4839.34253, 5022.94635, 5022.38078, 4902.75438,
       4994.64493, 4932.86099, 4683.29936, 4722.75382, 4743.37362,
       4688.72833, 4495.93811, 4787.7893 , 3961.34147, 4736.5071 ,
       4835.24243, 4856.73858, 4918.35419, 4947.42821, 4901.42942,
       4314.19638, 4771.05937, 4353.13379, 4853.08763, 4770.15415,
       4723.32267, 4816.88804, 3920.34793, 4702.07524, 4061.55554,
       4578.59249, 4435.35498, 4441.80618, 4370.96765, 4582.58651,
       4544.92423, 3881.38498, 3889.2194 , 3962.07242, 4106.76773,
       4121.64034, 4135.43492, 4391.92629, 4511.75509, 4287.60609,
       4371.85881, 4433.02929, 4226.1649 , 4238.18637, 6074.5569 ,
       4530.31137, 5076.39345, 4831.66804, 4536.69295, 4671.33996,
```



SUMMARY

- 피쳐의 개념과 표기법
- 데이터의 종류
 - 수치형 데이터
 - 연속형 데이터
 - 이산형 데이터
 - 범주형 데이터
 - 명목형 데이터
 - 서수형 데이터
- 데이터 테이블의 기본 용어
 - Matrix=Table
 - Column=열=Feature=특성=Attribute=속성
 - Row=행=Tuple=Instance
- 데이터를 수식에 적용는 실습



Q&A

궁금한 사항은 아래 방법으로 문의 바랍니다.



이메일
dana1112@bible.ac.kr



LMS 쪽지

THANK YOU FOR YOUR ATTENTION!

한국성서대학교 | 인공지능융합학부 | 머신러닝